

1. Introducción a la Incertesa en Jocs

El documento introduce el concepto de juegos donde el resultado de una acción no es determinista, sino que implica incertidumbre (juegos de azar o con información imperfecta).

- **Problemas no deterministas:** Situaciones donde no conocemos el resultado exacto de una acción, como pedir una carta en el solitario, probar una mina en el buscaminas o el movimiento aleatorio de fantasmas en Pacman¹¹¹¹¹¹¹¹¹.
- **Fuentes de incertesa:** Pueden surgir por procesos inherentemente aleatorios (dados), información insuficiente, ignorancia de procesos subyacentes o ruido en el entorno²²²².

2. Conceptos de Probabilidad y Utilidad

Para manejar la incertidumbre, se utilizan nociones matemáticas específicas:

- **Variable Aleatoria:** Formalización de un proceso que puede tener diversos resultados³.
- **Distribución de Probabilidad:** Conjunto de posibles resultados y sus probabilidades asociadas (siempre suman 1 y son no negativas)⁴⁴⁴⁴⁴⁴⁴⁴⁴.
- **Esperanza (Valor Esperado):** Es el valor medio ponderado de una función. Se calcula sumando el producto de cada valor posible por su probabilidad:
$$E[f(X)] = \sum_{x} f(x)P(x)$$
⁵.
- **Utilidad:** Medida abstracta para cuantificar el valor o recompensa de un estado según las preferencias del agente (ej. ganar = +1, perder = -1)⁶⁶⁶⁶.
- **Principio de Máxima Utilidad Esperada:** Un agente racional debe elegir la acción que maximice la utilidad media basada en su conocimiento actual⁷.

3. Algoritmo Expectimax

El algoritmo **Expectimax** es la adaptación del Minimax para entornos con incertidumbre.

- **Estructura del Árbol:**
 - **Nodos MAX:** El agente decide la mejor acción (igual que en Minimax).
 - **Nodos CHANCE (Azar):** Representan el turno de la naturaleza o un oponente aleatorio. En lugar de minimizar, calculan el **valor esperado** (promedio ponderado) de los sucesores⁸⁸⁸⁸.

- **Cálculo:**
 - Si es nodo MAX: Devuelve el máximo valor de los sucesores⁹.
 - Si es nodo CHANCE: Devuelve la suma de (valor del sucesor $\times$ probabilidad del sucesor)¹⁰.
- **Diferencia con Minimax:** Minimax asume un oponente óptimo; Expectimax modela resultados probabilísticos¹¹.

4. Funciones de Evaluación en Expectimax

Este es un punto crítico para el examen teórico:

- **Magnitud vs. Orden:** En Minimax, solo importa el orden relativo de los valores (saber qué estado es mejor). En Expectimax, **la magnitud de los valores es fundamental**¹²¹²¹²¹².
- **Transformaciones:** Una transformación lineal que preserve el orden puede cambiar la decisión óptima en Expectimax, porque altera el promedio ponderado. Por tanto, las funciones de evaluación deben reflejar correctamente las probabilidades de ganar¹³¹³¹³¹³.

5. Aplicaciones y Variantes

- **Backgammon (TD-Gammon):** Ejemplo clásico de uso de Expectimax debido a los dados. Utiliza una búsqueda a 2 niveles combinada con una buena función de evaluación aprendida (Temporal Difference Learning)¹⁴¹⁴¹⁴¹⁴.
- **Juegos de Suma No Cero:** Juegos con múltiples jugadores (más de 2) o donde la ganancia de uno no implica la pérdida exacta del otro.
 - Las utilidades se representan como **tuplas** (ej. [Valor A, Valor B, Valor C])¹⁵.
 - Cada jugador busca maximizar su propio componente de la tupla y propaga ese resultado hacia arriba en el árbol¹⁶¹⁶¹⁶¹⁶.

1. Conceptos Fundamentales

El aprendizaje por refuerzo se basa en un agente que interactúa con un entorno aprendiendo a través de "premios" o "castigos" sin conocer las reglas a priori.

- **Ciclo de Interacción:** El agente observa un estado (S_t), ejecuta una acción (a_t) y recibe una recompensa (r_{t+1}) y un nuevo estado (S_{t+1}) del entorno¹.
- **Objetivo:** El agente debe aprender una política (π) para maximizar la recompensa esperada acumulada a lo largo del tiempo².
- **Problema de la Recompensa Dispersa:** En muchos escenarios (ajedrez, carreras), la recompensa solo llega al final o raramente, dificultando el aprendizaje paso a paso³.

2. Aprendizaje Pasivo (Evaluación de Políticas)

En este escenario, la política del agente (π) es fija. El objetivo es aprender el valor de utilidad $V(s)$ de los estados siguiendo esa política⁴.

- **Estimación Directa de la Utilidad:** Se calcula el valor de un estado simplemente promediando las recompensas obtenidas en todos los episodios que pasaron por ese estado. Ignora la estructura secuencial de los estados⁵.
- **Programación Dinámica Adaptativa (ADP - Basado en Modelo):**
 - El agente aprende el modelo del entorno: estima la función de transición $T(s,a,s')$ y la recompensa R contando frecuencias de lo que observa⁶.
 - Una vez estimado el modelo, resuelve las ecuaciones de Bellman para calcular $V(s)$. Es costoso computacionalmente⁷.
- **Diferencia Temporal (TD - Libre de Modelo):**
 - No construye un modelo T ni R . Actualiza la utilidad de un estado basándose en la diferencia entre la estimación actual y la nueva muestra observada ($r + \text{valor del siguiente estado}$).
 - **Fórmula de actualización:** $U[s] \leftarrow U[s] + \alpha (r + \gamma U[s'] - U[s])$ ⁸.
 - Aquí, α es la tasa de aprendizaje. El aprendizaje ocurre en cada paso, no al final del episodio.

3. Aprendizaje Activo (Q-Learning)

Aquí el agente debe aprender la política óptima π^* y decidir qué acciones tomar (no sigue una política fija). Se descarta el aprendizaje de $V(s)$ para aprender directamente la calidad de los pares estado-acción, denotada como $Q(s,a)$ ⁹.

- **Algoritmo Q-Learning:**

- Es un método iterativo libre de modelo (similar a TD).
- Ecuación de actualización:

$$Q(s,a) \leftarrow (1-\alpha)Q(s,a) + \alpha [R(s,a,s') + \gamma \max_{a'} Q(s',a')]$$
¹⁰.
- A diferencia de TD pasivo, utiliza el operador **max** para estimar el valor futuro óptimo, independientemente de la acción que tome después.

- **Propiedad de Convergencia:** Q-Learning converge a la política óptima si se exploran suficientes estados y la tasa de aprendizaje α decrece apropiadamente, independientemente de cómo se seleccionen las acciones durante el entrenamiento¹¹.

4. Dilema Exploración vs. Explotación

Para aprender la política óptima, el agente debe equilibrar dos comportamientos:

1. **Explotación:** Elegir la mejor acción conocida según los valores Q actuales (maximizar recompensa inmediata).
2. **Exploración:** Elegir acciones desconocidas o menos probadas para descubrir mejores rutas a largo plazo¹².

Estrategias de Selección de Acción:

- **ϵ -greedy (Voraz):** Con probabilidad $1-\epsilon$ elige la mejor acción (explotación), y con probabilidad ϵ elige una acción aleatoria (exploración)¹³.
- **Funciones de Exploración:** Modifican el valor estimado de una acción para favorecer las menos visitadas.
 - Fórmula: $f(u,n) = u + k/n$, donde u es la utilidad y n el número de veces que se ha visitado el estado/acción. Si n es bajo, el valor aumenta artificialmente para forzar la visita¹⁴.

5. Parámetros Críticos (Para Problemas Numéricos)

Para los ejercicios prácticos de examen, preste atención a estos parámetros:

- **γ (Factor de descuento):** Determina cuánto importan las recompensas futuras frente a las inmediatas. $\gamma=0$ hace al agente miope; $\gamma=1$ le da igual peso al futuro lejano¹⁵.
- **α (Tasa de aprendizaje):** Controla qué tan rápido se olvida la información vieja para aceptar la nueva. Si $\alpha=1/N$, el cálculo equivale a hacer la media aritmética de todas las muestras¹⁶.

1. Definición y Componentes de un MDP

Un Proceso de Decisión de Markov es un marco formal para la toma de decisiones en entornos estocásticos (con incertidumbre) donde el resultado de las acciones no es totalmente determinista¹.

Un MDP se define por la tupla:

- **S (Estados):** Conjunto de estados posibles (ej. casillas en una graella)².
- **A (Acciones):** Conjunto de acciones disponibles para el agente (ej. Norte, Sur, Este, Oeste)³.
- **T (Transición):** La función de probabilidad $T(s, a, s') = P(s' | s, a)$. Define la probabilidad de llegar al estado s' desde s ejecutando la acción a ⁴.
- **R (Recompensa):** La función de recompensa inmediata $R(s, a, s')$ o simplemente $R(s)$. Define el beneficio (o coste) de estar en un estado o realizar una transición⁵.

La Hipótesis de Markov: El estado actual resume toda la información relevante del pasado. El futuro depende solo del presente, no de la historia anterior⁶.

2. Objetivo: La Política Óptima (π^*)

El objetivo no es solo planificar una secuencia fija (como en búsqueda determinista), sino encontrar una **política** (π).

- Una política es una función $\pi: S \rightarrow A$ que asigna la mejor acción a tomar para cada estado⁷.
- La **política óptima** maximiza la **utilidad esperada** (suma de recompensas) a lo largo del tiempo.

3. Utilidad y Descuento Temporal (γ)

Para comparar secuencias de recompensas infinitas, se utiliza la Utilidad Aditiva con Descuento:

$$U([r_0, r_1, r_2, \dots]) = r_0 + \gamma r_1 + \gamma^2 r_2 + \dots$$

⁸

El factor de descuento ($0 < \gamma < 1$):

1. Garantiza que la utilidad sea finita (convergencia matemática)⁹.

2. Refleja la preferencia por recompensas inmediatas frente a lejanas ("Más vale pájaro en mano...")¹⁰.

4. Las Ecuaciones de Bellman

Son el núcleo matemático para resolver MDPs. Relacionan el valor de un estado con el valor de sus sucesores.

- Valor de un Estado ($V^*(s)$): El valor máximo esperado desde s actuando óptimamente.

$$V^*(s) = \max_a \sum_{s'} T(s,a,s') [R(s,a,s') + \gamma V^*(s')]$$

11

- Valor de Acción ($Q^*(s,a)$): El valor de tomar la acción a en el estado s y luego actuar óptimamente.

$$Q^*(s,a) = \sum_{s'} T(s,a,s') [R(s,a,s') + \gamma V^*(s')]$$

12

- Relación clave: La política óptima es simplemente elegir la acción que maximiza Q : $\pi^*(s) = \text{argmax}_a Q^*(s,a)$ ¹³.

5. Algoritmos de Resolución

Existen dos métodos principales para calcular la política óptima en un MDP:

A. Iteración de Valores (Value Iteration)

Calcula iterativamente los valores $V(s)$ hasta que convergen.

1. Inicializar $V_0(s) = 0$ para todos los estados.
2. En cada iteración k , actualizar todos los estados usando la Ecuación de Bellman (convirtiendo la igualdad en asignación):

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s,a,s') [R(s,a,s') + \gamma V_k(s')]$$

14
3. Repetir hasta que el cambio entre iteraciones sea despreciable ($\Delta < \theta$).
4. La política se extrae al final calculando qué acción maximiza el valor.

B. Iteración de Políticas (Policy Iteration)

Alterna entre dos pasos hasta que la política deja de cambiar¹⁵:

1. **Evaluación de Política:** Dado una política fija π , calcular su valor $V^\pi(s)$. Esto es un sistema de ecuaciones lineales (más simple que Bellman porque no hay $\max$)¹⁶.

2. **Mejora de Política:** Calcular una nueva política $\pi'(s)$ eligiendo la acción que maximiza el valor basándose en los valores calculados en el paso 1 (actuación voraz o *greedy*)¹⁷.

Comparativa:

- *Iteración de Valores:* Combina el cálculo de valores y política en cada paso. Es más simple pero puede requerir más iteraciones para estabilizar los valores numéricos exactos¹⁸.
- *Iteración de Políticas:* Separa claramente evaluación y mejora. Suele converger en menos iteraciones, pero cada iteración es computacionalmente más costosa ($O(n^3)$ para la evaluación exacta)¹⁹.